

Fractional Whitened Spectral Entropy: A High-Dimensional Topological Diagnostic Framework for LLM Hallucinations

Abstract 本文提出了一种无需依赖外部奖励模型（Reward Model）或探测器训练（Probe Training），直接在潜空间（Latent Space）诊断大语言模型（LLM）幻觉的零样本（Zero-shot）分析方法。我们通过数学证明，由于指令微调带来的分布偏移，表层输出分布的香农熵已无法准确反映模型的真实困惑度。在特征空间中，传统的留一化全量白化会导致基底信息丢失与噪声过度放大。为此，我们引入了分数阶马氏白化（Fractional Mahalanobis Whitening）与谱熵（Spectral Entropy）计算方法。实验表明，该方法在不同任务模式下揭示了显著的分布特征（ $p < 1e-10$ ）：事实检索错误表现为高维能量发散（高谱熵），而数学推理错误则表现为向启发式策略的退化（低谱熵）。

1. 幻觉的起源与表层熵增假说

在大语言模型中，“幻觉（Hallucination）”在认知科学上的映射是模型在参数空间内对事实关联的不确定性。

在理想的自回归生成框架下，给定输入 X ，下一个词元 y 的条件概率分布为 $P(y|X)$ 。若模型对事实确信，分布应呈现高度集中的狄拉克 δ 函数形态；若模型存在不确定性，分布应趋于平缓。因此，传统的困惑度探测手段通常计算首词输出的香农熵（Shannon Entropy）：

$$H(Y) = - \sum_{i=1}^{|V|} p_i \ln p_i$$

理论上，模型不确定性越高（越容易产生幻觉），其表层输出的香农熵 $H(Y)$ 越大。

2. 对齐策略导致的表层熵集中

然而，在实际的指令微调（SFT）模型（如 Gemma-2B-IT）中，表层香农熵探测法存在局限性。

为了遵循人类对话习惯，模型在强化学习与对齐阶段（RLHF）引入了固定的回答范式。这导致模型在面对多数提问时，其首批输出词元主要被“As an AI language model...”或“Sure, the answer is...”等高频词元占据。在数学上，这意味着在生成的初始阶段，这些模式化词元的概率 $P(y_{waste}|X) \rightarrow 1$ 。根据信息论，此时的首词香农熵：

$$H(Y_0) \approx -1 \cdot \ln(1) - 0 = 0$$

表层概率分布发生了显著的人为概率集中，掩盖了模型对后续具体事实的内部不确定性信号。

3. 潜空间分析与基底分解的必要性

由于输出分布受到对齐策略的影响，我们考虑绕过表层输出，直接对模型 Transformer 层前向传播产生的潜空间隐藏状态向量（Hidden States） $\mathbf{h} \in \mathbb{R}^d$ 进行特征分析。

在潜空间中，我们假定模型所在的高维特征空间是由若干代表独立语义的正交基底（Orthogonal Basis）构成的。我们需要评估向量 $\mathbf{h}$ 在这些基底上的能量分布状态，因此，矩阵分解（如 SVD）成为了提取主要语义参照系的有效方法。

4. 机制反思：直接观测 $\text{GeLU}(\mathbf{W}_1\mathbf{h})$ 的局限性

在进入 SVD 分析前，一个替代方案是直接观测前馈网络（FFN）的升维激活空间

$\mathbf{h}' = \text{GeLU}(\mathbf{W}_1\mathbf{h})$ ，因其具有稀疏性。然而，该方案存在两个主要局限：

1. **叠加态（Superposition）**：由于 $\dim(\mathbf{h}') \gg \dim(\mathbf{h})$ ，单个神经元往往是多义的（Polysemantic）。特定的语义概念通常由多个神经元的线性组合编码。
2. **参照系缺失**：直接计算稀疏激活向量的熵，反映的是激活模式本身的稀疏度，而非模型对特定知识的不确定度。它缺乏一个统一的、按方差排序的正交参照系。

5. FFN 输出向量的语义正交能量分布

我们直接对 FFN 层的输出特征进行分析。其核心逻辑如下：

设潜空间中存在正交语义基矩阵 $\mathbf{V} = [\mathbf{v}_1, \dots, \mathbf{v}_d]$ 。

- **正确答案的分布（局部正交基）**：当模型确信某事实时，其特征向量 $\mathbf{h}_{true}$ 主要由少数强相关的语义基底构成。即 $\mathbf{h}_{true} \approx \sum_{i \in \mathcal{K}} c_i \mathbf{v}_i$ ，其中集合 $|\mathcal{K}|$ 较小。投影后的能量分布较为集中。
- **幻觉的分布（高维泄漏）**：当模型产生幻觉时，由于缺乏主要知识成分支撑，该特征表现出分布外（OOD）特性。其能量会更均匀地分散到包含无关噪声的多个维度中：

$$\mathbf{h}_{false} = \sum_{i=1}^d c'_i \mathbf{v}_i$$

我们通过计算投影后的谱熵（Spectral Entropy）来量化这种能量的分散程度。

6. 维度放缩问题与分数阶白化（Fractional Whitening）的数学推导

对参考数据矩阵 $\mathbf{X} \in \mathbb{R}^{N \times d}$ 进行奇异值分解 $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ 。设 $\mathbf{x}_i$ 为矩阵 $\mathbf{X}$ 的第 i 个行向量（即某个测试样本），则 $\mathbf{x}_i = \mathbf{u}_i\mathbf{\Sigma}\mathbf{V}^T$ ，其中 $\mathbf{u}_i$ 是左奇异矩阵 $\mathbf{U}$ 的第 i 行。测试向量在正交基 $\mathbf{V}$ 上的投影定义为 $\mathbf{p}_i = \mathbf{x}_i\mathbf{V}$ 。

6.1 不进行白化（ $\alpha = 0$ ）的低频主导问题 当不进行白化时，直接计算投影向量：

$$\mathbf{p}_i = (\mathbf{u}_i\mathbf{\Sigma}\mathbf{V}^T)\mathbf{V} = \mathbf{u}_i\mathbf{\Sigma}$$

该向量的第 j 个维度的坐标分量为 $p_{ij} = u_{ij}\sigma_j$ 。由于 $\sigma_1 \gg \sigma_d$ ，前几个代表宏观语法或共有结构的奇异值在绝对数值上占据了主导地位。在计算谱熵时，其平方能量 $E_{ij} = u_{ij}^2\sigma_j^2$ 向头部维度集中。这导致谱熵整体偏低，幻觉样本在尾部较小维度上的能量分散信号被头部大能量稀释，组间统计差异微弱。

6.2 全量白化（ $\alpha = 1$ ）的各向同性转化 当执行全量白化时，我们在投影后乘以对角矩阵 $\mathbf{\Sigma}^{-1}$ ：

$$\tilde{\mathbf{p}}_i = \mathbf{p}_i\mathbf{\Sigma}^{-1} = (\mathbf{u}_i\mathbf{\Sigma})\mathbf{\Sigma}^{-1} = \mathbf{u}_i$$

此时，白化投影向量等价于左奇异矩阵 $\mathbf{U}$ 的行向量 $\mathbf{u}_i = [u_{i1}, u_{i2}, \dots, u_{ir}]$ 。由于在实际操作中，剔除零空间后得到的 $\mathbf{\Sigma}$ 为 $r \times r$ 的方阵（其中 $r \leq N$ 为有效维度），与之对应的左奇异矩阵 $\mathbf{U}$ 严格为一个 $r \times r$ 的正交方阵。在线性代数中，正交方阵不仅列向量正交，其行向量同样构成了 $\mathbb{R}^r$ 空间中的一组标准正交基。

在去除了奇异值对角矩阵 $\mathbf{\Sigma}$ 后， $\mathbf{u}_i$ 丧失了用于表征不同特征维度重要性的方差权重。此时 $\mathbf{u}_i$ 成为了多维空间中的各向同性（Isotropic）单位向量，其自身能量满足 $\sum_{j=1}^r u_{ij}^2 = \|\mathbf{u}_i\|_2^2 = 1$ 。

对于一个未知的测试样本，其投射到去权重后的任意一个维度上的能量期望具有对称性。根据全概率公式，其归一化后的能量分布期望为：

$$E[\mathcal{E}_{ij}] = E\left[\frac{u_{ij}^2}{\|\mathbf{u}_i\|_2^2}\right] = \frac{1}{r} \sum_{k=1}^r E[u_{ik}^2] = \frac{1}{r} E[1] = \frac{1}{r}$$

由于能量分配失去了奇异值权重的引导，表现为在所有 r 个维度上的均匀分布。无论该样本是正确答案还是幻觉，其谱熵都会趋近于理论最大值：

$$H_{spec} \rightarrow \ln(r)$$

此时，特征坐标转化为各向同性的随机噪声分布，组间差异变得不再显著。

6.3 分数阶白化方法（Fractional Whitening） 为解决上述两端问题，我们引入缩放系数 $\alpha \in (0, 1)$ ，构造分数阶白化投影：

$$\tilde{\mathbf{p}}_i^{(\alpha)} = \frac{p_i}{\sigma_i^\alpha + \epsilon}, \quad H_{spec}^{(\alpha)} = - \sum \mathcal{E}_i \ln \mathcal{E}_i$$

该机制有效抑制了低频主成分（通过部分衰减大 σ ），同时利用 σ^α 防止了向量向各向同性分布的完全转化，从而放大了幻觉样本在正交空间中能量分散的信号。

7. 基于谱分析的超参数观测与无监督定标

7.1 现象观测：基于 P -Value 扫描的分布变化 我们将 $\alpha \in [0, 1]$ 视作一种频谱调节参数。在事实冲突数据集中执行全参数扫描后，热力图显示，在中深层网络（Layer 18-21）与 $\alpha \approx 0.6$ 的区间，出现了显著的统计差异区域（ $p < 1e - 10$ ）。由于事实幻觉主要表现为能量分散，该区域呈现出一致的统计特征（幻觉熵 > 真理熵）。

7.2 方法论说明： α 的无监督定标 需要说明的是， $\alpha \approx 0.6$ 并非通过在特定测试集上进行有监督网格搜索（Grid Search）拟合而来的超参数。该参数可通过无监督方式提前计算得到。

在大语言模型中，奇异值 σ_i 的衰减近似服从幂律分布（Power-law Decay），即 $\sigma_i \propto i^{-\beta}$ ，其中 β 反映了模型特征空间的冗余度。引入 α 的目的是为了在计算有效秩空间内的谱熵时，平衡各维度的能量方差，避免尾部低能量维度的过度放大。因此， α 的最优解可直接通过无监督的离线语料库（Anchor Corpus）的协方差矩阵推导得出：

$$\alpha_{opt} = \operatorname{argmax}_{\alpha} \operatorname{Var} \left(\frac{\sigma_i}{\sigma_i^{\alpha}} \right) \quad \text{subject to } i \leq r_{eff}$$

该无监督推导方法不依赖特定任务标签，具有在不同模型架构间的理论泛化能力。

8. 降维分析：留一法（LOO/CV）在当前场景下的适用性讨论

针对“全量 SVD 计算是否存在数据泄漏风险”的问题，我们进行了留一化交叉验证（LOO-CV）的对比实验。结果表明，使用 LOO-CV 计算时，原有的显著差异分布失效， p 值呈现出随机分布图的特征。这种现象是由当前模型特征空间的高维特性决定的。

8.1 现象分析：潜空间的高秩特征 我们提取了协方差矩阵的奇异值分布。数据表明，在深层（如 L24），保留 90% 方差所需的有效秩达到 $r_{eff} = 381$ 。这意味着，这 2000 个查询样本并非存在于一个低维子空间中，而是构成了一个高秩的特征空间。每个样本可能包含正交于其他样本的特定语义维度。

8.2 数学分析：交叉验证导致的基底缺失与误差放大 设全量样本协方差为

$\mathbf{C}_{full} = \mathbf{C}_{train} + \mathbf{x}_{test}^T \mathbf{x}_{test}$ 。在 LOO 操作中，由于高秩性质，测试样本 $\mathbf{x}_{test}$ 中可能包含未曾在训练集 $\mathbf{C}_{train}$ 中出现过的正交分量 $\mathbf{v}_{unique}$ 。这意味着训练集基底 $\mathbf{V}_{train}$ 无法完全张成该语义方向。

当测试样本在 $\mathbf{V}_{train}$ 上进行投影时： $\mathbf{p}_{wrong} = \mathbf{x}_{test} \mathbf{V}_{train}$ 。由于 $\mathbf{V}_{train}$ 无法表示 $\mathbf{v}_{unique}$ ，这部分信号会被异常投影至 $\mathbf{C}_{train}$ 对应极小奇异值的尾部维度中。在执行分数阶白化 $\tilde{p}_j = p_{wrong,j} / (\sigma_j^{(train)})^{\alpha}$ 后，由于异常投影信号被极微小的 σ_j^{α} 放大，投影结果发生急剧的误差放大，谱熵快速逼近理论最大值，导致组间差异被噪声掩盖。

8.3 工业部署方案：离线语料库的子空间饱和 在实际应用中，无需在每次在线诊断时将新样本加入全集并重新进行 $O(N \cdot d^2)$ 的 SVD 计算。我们可以利用高维空间中的子空间饱和特性。

定义重构误差（Reconstruction Error）来衡量在线新样本 $\mathbf{x}_{new}$ 在静态参考基底 $\mathbf{V}_{ref}$ 上的信息损失：

$$\mathcal{E}_{recon}(\mathbf{x}_{new}) = \|\mathbf{x}_{new} - \mathbf{x}_{new} \mathbf{V}_{ref} \mathbf{V}_{ref}^T\|_2^2$$

有效秩 $r_{eff}(N)$ 是关于语料库样本量 N 的单调递增函数，但受限于大模型的固定隐藏层维度 d ， r_{eff} 存在数学上界。结合语言模型表示退化（Representation Degeneration）和各向异性（Anisotropy）的现有研究，LLM 实际张成的有效子空间维度往往低于其物理维度 d 。

因此，在部署时，可构建一个样本量足够大且具备领域多样性的离线语料库（Anchor Corpus）。当语料库规模达到一定程度后，其协方差矩阵的子空间将趋于饱和，基本覆盖该模型能表示的主要正交子空间。对于绝大多数域内新样本 $\mathbf{x}_{new}$ ：

$$\lim_{N \rightarrow \text{large}} \mathcal{E}_{recon}(\mathbf{x}_{new}) \rightarrow \epsilon \approx 0$$

在基底饱和的前提下,可直接依赖离线计算好的 $\mathbf{V}_{ref}$ 与 Σ_{ref} , 对新样本执行 $O(d^2)$ 的静态投影, 以实现高效的在线计算。

9. 实验扩展：数学逻辑推理任务中的分布特征

最后, 我们将该方法应用于逻辑推理数据集 (Math Logic)。实验结果呈现出与事实冲突任务不同的统计分布特征。

9.1 现象陈述与 α 参数的频段对应 α 参数的大小调节了不同特征维度的权重：

- 较小的 α ：投影主要由较大奇异值 σ_i (低频/主成分, 代表宏观语法或共有结构) 主导。
- 较大的 α ：衰减因子部分抑制了主成分, 增加了较小奇异值 (高频/尾部成分, 代表具体逻辑运算特征) 的相对权重。

在此参数设置下, 中深层观察到了如下统计特征：

- 低 α 区域：正确回答组表现为低谱熵 (即幻觉熵 > 真理熵)。
- 高 α 区域：正确回答组表现为高谱熵 (即真理熵 > 幻觉熵)。

9.2 物理成因分析：结构一致性与算法特征 这种统计分布差异可以映射到语言模型处理逻辑推理任务的过程：

1. 低 α 区域 (低频主导, 正确组低熵)：正确的数学推导外壳通常具有较强的结构一致性 (例如特定的推理模板)。因此, 其在代表宏观结构的低频基底上能量收敛较好, 谱熵较低。而错误推理往往难以维持这种固定的格式模板, 导致在低频主成分上的能量分散, 熵值相对较高。
2. 高 α 区域 (高频主导, 正确组高熵)：正确的数学推导过程涉及多种逻辑算子和变量状态的追踪, 这些特征往往对应于多个高频维度。因此, 正确组的高频能量分布较广, 产生高熵区域。相反, 当模型推理错误时, 往往退化为简单的启发式猜测 (如直接复制特定数字), 使得高频能量向少数特征维度集中, 熵值急剧下降。

该结果表明, 分数阶白化方法能够有效捕捉模型在事实提取和逻辑推理过程中不同的高维分布特征。