

Fractional Whitened Spectral Entropy: A High-Dimensional Topological Diagnostic Framework for LLM Hallucinations

Abstract 本文提出了一种无需依赖外部奖励模型（Reward Model）或探测器训练（Probe Training），直接在潜空间（Latent Space）诊断大语言模型（LLM）幻觉与认知坍缩的零样本（Zero-shot）拓扑方法。我们通过数学证明，由于“对齐税（Alignment Tax）”的存在，表层输出分布的香农熵已无法反映模型的真实困惑度。在特征空间中，传统的留一化全量白化会导致“子空间塌缩”与噪音核爆。为此，我们引入了分数阶马氏白化（Fractional Mahalanobis Whitening）与谱熵（Spectral Entropy）引擎。实验表明，该引擎在不同任务模式下揭示了极其显著的相关物理特性（ $p < 1e - 10$ ）：事实检索表现为高维能量发散（单极高熵），而数学推理则表现为算法电路的启发式坍缩（双极低熵）。

1. 幻觉的起源与表层熵增假说

在大语言模型中，“幻觉（Hallucination）”在认知科学上的本质映射是模型在参数空间内对事实关联的“困惑（Confusion）”或“不确定性”。

在理想的自回归生成框架下，给定输入 X ，下一个词元 y 的条件概率分布为 $P(y|X)$ 。若模型对事实确信，分布应呈现极度尖锐的狄拉克 δ 函数形态；若模型困惑，分布应趋于平缓。因此，传统的困惑度探测手段通常计算首词输出的香农熵（Shannon Entropy）：

$$H(Y) = - \sum_{i=1}^{|V|} p_i \ln p_i$$

理论上，模型越困惑（容易产生幻觉），其表层输出的香农熵 $H(Y)$ 越大。

2. 对齐税（Alignment Tax）导致的表层熵坍缩

然而，在实际的指令微调（SFT）模型（如 Gemma-2B-IT）中，表层香农熵探测法彻底失效。

为了遵循人类对话习惯，模型在强化学习与对齐阶段（RLHF）缴纳了沉重的“对齐税”。这导致模型在面对任何提问时，其首批输出词元几乎被“As an AI language model...”或“Sure, the answer is...”等高频废话（Waste Words）强行占据。在数学上，这意味着在生成的初始阶段，无意义词元的概率 $P(y_{waste}|X) \rightarrow 1$ 。根据信息论，此时的首词香农熵：

$$H(Y_0) \approx -1 \cdot \ln(1) - 0 = 0$$

表层概率分布发生了严重的人为坍缩（Artificial Collapse），彻底屏蔽了模型对后续真实事实的内部困惑信号。

3. 潜空间下探与基底分解的必要性

由于输出分布被对齐税遮蔽，我们必须穿透表层，直接对模型 Transformer 层前向传播产生的潜空间隐藏状态向量（Hidden States） $\mathbf{h} \in \mathbb{R}^d$ 进行拓扑分析。

在潜空间中，如何定义“困惑”？我们假定，模型所在的高维特征空间是由若干代表独立语义的正交基底（Orthogonal Basis）构成的。我们需要评估向量 $\mathbf{h}$ 在这些基底上的能量分布状态，因此，矩阵分解（如 SVD）成为了提取宏观语义参照系的必然选择。

4. 机制反思：为何拒绝直接观测 $\text{GeLU}(\mathbf{W}_1\mathbf{h})$

在进入 SVD 架构前，一个直观的替代方案是直接观测前馈网络（FFN）的升维激活空间 $\mathbf{h}' = \text{GeLU}(\mathbf{W}_1\mathbf{h})$ ，因为它具有极强的稀疏性。然而，该方案在物理上面临两堵高墙：

1. 叠加态（Superposition）：由于 $\dim(\mathbf{h}') \gg \dim(\mathbf{h})$ ，单个神经元往往是“多义的（Polysemantic）”。真实的语义概念是由多个神经元的特定线性组合编码的。
2. 绝对坐标失效：直接计算稀疏激活向量的熵，反映的是该知识本身的“固有稀疏度”，而非模型对此知识的“困惑度”。它缺乏一个统一的正交能量参照系。

5. FFN 输出向量的语义正交能量法则

我们直接对 FFN 层的输出特征进行分析。其核心物理逻辑如下：

设潜空间中存在正交语义基矩阵 $\mathbf{V} = [\mathbf{v}_1, \dots, \mathbf{v}_d]$ 。

- 真理的拓扑（局部正交基）：当模型确信某事实时，其特征向量 $\mathbf{h}_{true}$ 仅激活极少数强相关的语义基底。即 $\mathbf{h}_{true} \approx \sum_{i \in \mathcal{K}} c_i \mathbf{v}_i$ ，其中集合 $|\mathcal{K}|$ 极小。投影后的能量分布极其集中。
- 幻觉的拓扑（高维泄漏）：当模型产生幻觉（胡编乱造）时，由于缺乏强知识主成分支撑，该特征处于分布外（OOD）状态。其能量会不可避免地泄漏（Leakage）到大量本该死寂的正交噪音维度中： $\mathbf{h}_{false} = \sum_{i=1}^d c'_i \mathbf{v}_i$ 。

我们通过计算投影后的谱熵（Spectral Entropy）来量化这种能量发散度。

6. 维度灾难与分数阶白化（Fractional Whitening）的推导

对参考数据矩阵 $\mathbf{X}$ 进行奇异值分解 $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ 。测试向量 $\mathbf{x}$ 在正交基上的投影为 $\mathbf{p} = \mathbf{x}\mathbf{V}$ 。

- 完全不白化（ $\alpha = 0$ ）的失效：谱熵 H_{spec} 仅由最大的几个主成分（代表所有句子的共同语法或句法结构）绝对统治。幻觉在极小噪音维度上的微弱泄漏信号，被第一主成分的绝对能量稀释殆尽，导致组间差异微弱。
- 全量马氏白化（ $\alpha = 1$ ）的核爆灾难：白化公式为 $\tilde{p}_i = p_i / \sigma_i$ 。对于大量代表底噪的尾部特征， $\sigma_j \rightarrow 0$ 。如果对 2048 维进行全量白化，尾部噪音维度被放大无穷倍，产生能量核爆。所有样本的投影都被强行撕裂为均匀的白噪音，导致显著性彻底丧失（见热力图上方区域）。
- 分数阶白化引擎（Fractional Whitening）：为打破僵局，我们引入阻尼系数 $\alpha \in (0, 1)$ ，构造分数阶白化投影：

$$\tilde{\mathbf{p}}_i^{(\alpha)} = \frac{p_i}{\sigma_i^\alpha + \epsilon}$$

$$H_{spec}^{(\alpha)} = - \sum \mathcal{E}_i \ln \mathcal{E}_i, \quad \text{where} \quad \mathcal{E}_i = \frac{(\tilde{\mathbf{p}}_i^{(\alpha)})^2}{\sum (\tilde{\mathbf{p}}_j^{(\alpha)})^2}$$

该机制在压制语法主成分（大 σ ）的同时，为尾部噪音提供了 σ^α 的平滑底线，完美放大并捕获了事实幻觉的异常泄漏。

7. 实验现象 A：事实冲突空间的单极相变

在事实冲突数据集中执行 α 扫描，我们获得了极其震撼的显著性相变热力图（ T -test, $-\log_{10}(p)$ ）。正如理论预测，在深层网络（Layer 18-21）与 $\alpha \approx 0.6$ 的奇点区域，出现了代表极度显著的“暖色太阳”（ $p < 1e-10$ ）。由于事实幻觉永远表现为“能量发散泄漏”，该热力图呈现完美的单极相变特征（幻觉熵 $\gg$ 真理熵）。

8. 降维解构：高秩流形与反交叉验证定理

为了探究参考系构建的严密性，我们对协方差矩阵的奇异值分布进行了剖析。数据揭示了深层大模型潜空间的“高秩马赛克结构（High-Rank Mosaic Structure）”。例如，在 L24 层，90% 的能量分散在多达 381 个奇异值上（有效秩 $r_{eff} = 381$ ）。

这一物理观测给出了极其严厉的警告：在此流形中，传统的 K-Fold 交叉验证（CV）或留一化（LOO）是导致子空间塌缩的致命操作。

- 数学证明：设全量协方差 $\mathbf{C}_{full} = \mathbf{C}_{train} + \mathbf{C}_{test}$ 。由于每个样本均包含独立的正交孤品知识（由高维 r_{eff} 保证），强行剥离测试集会导致训练基底 $\mathbf{V}_{train}$ 丢失特定语义方向。当测试样本在残缺的 $\mathbf{V}_{train}$ 上投影时，其真实能量无处安放，必然导致严重的伪投影泄漏。此时再执行除以微小 σ^α 的操作，谱熵将被瞬间炸毁至理论上限。因此，构建全量 SVD 基底（Full-Sample SVD）不是数据泄露，而是确立完整相对论参照系的唯一合法途径。

9. 实验现象 B：数学逻辑空间的双极拓扑分离

最后，我们将该引擎应用于纯粹的逻辑推理数据集（Math Logic）。相变热力图呈现出与事实冲突截然不同、却又极其自洽的双极物理形态（Bipolar Topology）。

9.1 现象陈述与 α 滤波器的物理定义

在观察实验结果前，必须明确 α 参数在 SVD 正交基上的物理映射关系： α 本质上是一个“频谱滤波器（Spectrum Filter）”。

- 当 α 较小时（ $\alpha \rightarrow 0$ ），投影能量被庞大的奇异值 σ_i （低频/主成分，代表宏观语法与共有结构）所绝对主导。
- 当 α 较大时（ $\alpha \rightarrow 1$ ），衰减因子 $\sigma_i^{-\alpha}$ 强行压制了主成分，并放大了微小的奇异值（高频/尾部成分，代表极度细分的具体知识与微观逻辑运算）。

在这一物理定义下，我们在中深层（Layer 13-20）观察到了双极反转现象：

- 红区（中 α 频谱）：正确回答组表现为极低熵（幻觉熵 $\gg$ 真理熵）。
- 蓝区（高 α 频谱）：正确回答组表现为极高熵（真理熵 $\gg$ 幻觉熵）。

9.2 物理成因推导：分布式算法电路 vs 启发式坍缩

这种在同一个问题上，中低频呈现低熵、高频呈现高熵的拓扑奇观，完美映射了大模型进行数学逻辑推理时的物理运作机制。

1. **红区的物理含义：宏观结构的低秩收敛（中低频低熵）** 数学推理的表层外壳具有极其严苛的结构刚性（例如：“已知条件是...”、“因此我们可以得出...”）。正确的逻辑推演必须完美遵循这些宏观范式，因此其特征向量在第一主成分至中频特征（中低频基底）上实现了极度的能量收敛，导致谱熵极低。而产生幻觉的模型往往连宏观的推理格式都无法维持，导致能量偏离主干成分产生泄漏（高熵）。
2. **蓝区的物理含义：微观电路的宽带分布（高频高熵）** 当 α 升高，我们的探针切入高频的细分逻辑基底时，物理法则发生了反转。正确的数学推导绝不是像检索“巴黎”那样唤醒单一的低维知识点。它必须唤醒一个庞大的“分布式算法电路（Distributed Algorithmic Circuit）”（包括状态寄存、进位算子、变量追踪器）。正确的推理意味着特征向量的能量必须同时且均匀地分布在大量代表微观逻辑算子的高频维度上（宽带分布），从而结构性地产生了极高熵的深蓝色极值区。相反，数学错误往往源于“算法坍缩（Algorithmic Collapse）”。模型无法维持这套复杂的分布式电路，退化为低秩的启发式猜测（例如直接抄写 Prompt 中的某个数字，放弃逻辑运算），导致高频能量急剧向极少数维度集中，熵值瞬间暴跌。

该双极图谱不仅验证了 α 引擎作为频谱分析仪的完美性，更在数学层面证明了：大模型的“事实提取（点状低秩）”与“逻辑推理（宽带电路）”拥有完全相反的高维拓扑物理表现。